Notas de Análise — Percolação Multicores: Evento Raro, Erros e Métricas

Contexto

Quando rodamos muitas seeds para um conjunto de parâmetros (ρ, p0, etc.), pode acontecer de poucas seeds apresentarem pelo menos uma cor percolando (evento raro). Isso cria duas questões: (1) como reportar a "raridade" e (2) como calcular erros das médias das séries (pt, nt) de forma correta.

Decisão (Prática Acadêmica Padrão)

Separar duas camadas de informação:

1) Incidência de percolação (binomial):
   - Para cada (ρ, p0, ordem), definimos N = número total de seeds (arquivos) processadas, e M = número de seeds que percolaram naquela ordem (i.e., contribuíram com série).
   - Reportamos a taxa de percolação $\hat{q} = M/N$ com intervalo de confiança binomial. Recomendação: IC de Wilson (ou Agresti–Coull; Clopper–Pearson é mais conservador).

2) Observáveis condicionais ao evento:
   - As médias pt_mean / nt_mean e seus erros (pt_erro / nt_erro) são calculados *apenas* sobre as M seeds que percolaram naquela ordem (média condicional).
   - Null (seeds sem percolação) NÃO entram na média condicional.

Consequência

Se M for pequeno (p.ex. 1), o SEM entre-seeds tende a 0 (pois há 1 amostra). Isso não significa certeza; a incerteza da ocorrência do evento está explicitamente capturada em $\hat{q}$ com seu IC binomial. Assim, comunicamos separadamente:
- "Quão raro é percolar" (via $\hat{q}$±IC), e
- "Qual é o valor médio quando percola" (via pt_mean/nt_mean ± SEM condicional).

Métrica opcional (unificada)

Se for desejado um valor "incondicional", pode-se usar

$$\mu_{uncond} = \hat{q} \cdot \mu_{cond}$$

e o erro por propagação (delta method):

$$SE(\mu_{uncond}) \approx \sqrt{\mu_{cond}^2 \cdot Var(\hat{q}) + \hat{q}^2 \cdot SE(\mu_{cond})^2}$$

com $Var(\hat{q}) \approx \hat{q}(1-\hat{q})/N$. Essa métrica mistura raridade + variabilidade condicional, mas use-a apenas se fizer sentido físico (p.ex., observável também definido quando não há percolação).

Definições usadas no DataFrame

Colunas principais por (ρ, p0, ordem):
- num_samples   = N (nº total de seeds lidas para aquele p0 — mesmo vazias)
- num_sample_perc   = M (nº de seeds que percolaram naquela ordem)
- perc_rate   = q^ = M / N (taxa de percolação por ordem)
- perc_ci_low/high   = limites inferior e superior do IC de Wilson para q^
- pt_mean, pt_erro   = média condicional e SEM (entre-seeds que percolaram)
- nt_mean, nt_erro   = idem para nt
- pt_mean_uncond, pt_erro_uncond (opcional, ver fórmula acima)
- nt_mean_uncond, nt_erro_uncond (opcional)

Boas práticas

- Apresente figuras/tabelas com dois painéis: em cima q^(ρ,p0) ± IC; embaixo μ_cond ± SEM (para pt e/ou nt). Para M muito pequeno, considere também mediana e IQR ou bootstrap.
- Se o tempo até percolar importa e muitas seeds não percolam no horizonte de simulação, trate como censura e use sobrevivência (Kaplan–Meier) para “tempo até primeira percolaçã

Resumo operacional (o que seu código faz agora)
---
1) Conta N (num_samples) por p0 como o número total de arquivos processados para aquele p0
2) Para cada ordem, conta M (num_sample_perc) = quantas seeds contribuíram com série.
3) Calcula pt_mean/nt_mean e seus SEM *condicionais* sobre as M seeds.
4) Adiciona perc_rate e IC de Wilson para comunicar a raridade.
5) (Opcional) Calcula métricas incondicionais via propagação de erro.

Interpretação de um caso raro

Exemplo: num_samples = 100, num_sample_perc = 1, pt_mean ≈ 1.0 e pt_erro ≈ 0.0.
- Raridade: q^ = 1% com IC amplo (binomial).
- Condicional: quando percola, a média observada foi ~1.0 (SEM ~ 0 pela amostra única).
- Incondicional (opcional): ~0.01, com erro dominado pela incerteza em q^.

Referências rápidas

- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inferen
- Agresti, A., & Coull, B. A. (1998). Approximate is better than “exact” for interval estimation of binomial proportions.
- Newman, M. (2010). Networks (cap. percolation).
- Stauffer & Aharony (1994). Introduction to Percolation Theory.